

基于多模态 Transformer 的机电作动器剩余寿命预测技术研究¹

陈子涵

(中国空间技术研究院 遥感卫星总体部, 北京 100094)

摘要: 机电作动器在航空航天装备中扮演着重要的角色。针对机电作动器剩余寿命预测问题, 提出一种基于多模态 Transformer 模型的机电作动器寿命预测方法。该方法直接使用多通道传感器数据作为输入, 综合考虑多模态数据信息, 并且不需要人工特征提取等预处理步骤。多模态 Transformer 模型利用多头自注意力机制从不同的表示子空间中自适应学习全局特征, 能够避免传统深度学习方法难以学习全局特征的缺点。利用多模态 Transformer 的编码器部分并行提取多模态传感器时间序列中不同传感器的特征, 并实时直接预测剩余使用寿命。采用由编码器和解码器组成的完整多模态 Transformer 模型预测机电作动器的关键性能参数, 可同时更直观地预测关键寿命参数的退化过程。使用机电作动器全寿命试验数据验证该方法用于寿命预测的有效性。试验结果表明, 本文提出的方法能够准确地直接预测剩余寿命, 同时预测关键性能参数的寿命退化过程。

关键词: 多模态数据; 注意力机制; 机电作动器; 寿命预测

中图分类号: V474 **文献标志码:** A

Remaining Useful Life Prognostic for Electro-Mechanical Actuators Based on Multimode Transformer

CHEN Zihan

(Institute of Remote Sensing Satellite, China Academy of Space Technology, Beijing 100094, China)

Abstract: Electro-mechanical actuators play an important role in the next generation spacecraft. Aiming at the problem of the remaining useful life prediction of electro-mechanical actuators, a failure prognostic algorithm based on a multi-mode Transformer model is proposed. Multi-channel sensor data are directly used as inputs to the Transformer model without feature extraction as a pre-processing step. Multimode Transformer makes use of multi-head attention to adaptively learn the global features from various representation subspaces. The Encoder of the Transformer is utilized to extract features of different sensors over the time series in parallel and predict the remaining useful life directly. Simultaneously, the full Transformer composed of Encoder and Decoder is used to prognosticate key performance parameters of electro-mechanical actuators. A benchmark dataset was used to validate the effectiveness of the proposed model for electro-mechanical actuator failure prognostic. The experimental results reveal our advantage in accurate remaining useful life prediction and failure prognostic.

Keywords: multimode data; attention mechanism; electro-mechanical actuator; failure prognostic

0 引言

近年来, 下一代配备电传飞控系统的航天装备日益增加^[1]。机电作动器 (EMA) 作为一种重要的电传飞控作动器, 由于具有更高的可靠性、更低的总重量、更好的可维护性等优点, 在航天工业中得到了越来越多的关注和应用。EMA是航天器上重要

的执行机构之一, 航天器复杂的工作环境可能会导致多样的EMA故障。航天装备对EMA的安全性和可靠性要求很高, 未被发现的EMA故障可能会导致灾难性的后果。因此, 开展航天器EMA的故障诊断和寿命预测研究具有重要意义。

EMA由电气、电子和机械部分组成, 会呈现复杂的故障模式。考虑到航天系统对安全方面的严格要求, 必须实现准确的寿命预测, 从而在灾难性故

障发生之前留出足够的时间进行应急管理。数年来,在EMA的故障预测与健康领域已有很多研究。这些研究提出的方法基本上可以分为两类^[2]:基于模型的方法和数据驱动的方法。

基于模型的方法需要建立一个准确的数学模型,从而预测EMA的输入和输出关系,或者估计EMA内部状态量的变化规律。通过将模型估计的参数与真实测量的参数进行比较,可以识别EMA的性能状态或健康状态。基于模型的方法可以跟踪EMA中的单个组件的运行状态,从而直接从物理角度识别故障。这类方法能够实现非常具体的故障识别,并且能够实时查看特定组件的健康状态。文献[3]使用遗传算法在EMA性能下降初期识别故障征兆。文献[4]考虑的EMA及上级控制系统的详细模型,设计了五组基于信号的监控功能,并通过基于信号的规则来检测和定位系统的相关故障。该方法需要大量而准确的先验知识和预先设计的规则。文献[5]基于EMA的线性模型设计了线性残差滤波器,并通过基于零空间的残差滤波器监视EMA的3个传感器实现故障诊断。文献[6]通过物理第一性原理建立EMA动态模型,模拟EMA的动力学中涉及的最相关现象,从而检测瞬态故障特征。这两种方法依赖于高保真模型,而高保真模型通常是根据特定设备设计的,并且需要监测的参数往往是实验室阶段才能监测到。基于模型的方法的优点是在故障模式和模型参数之间有一组清晰的对应关系。然而基于模型的方法中使用的模型往往过于复杂,其完整的模型参数在非实验室阶段难以获得,或者对测量和计算要求非常高。同时,对于基于模型的方法,每个新产品和新应用场景都必须有一个新的经过验证的模型。因此,虽然上述基于模型的方法在EMA的故障诊断方面表现良好,但是其应用条件苛刻,在面对工程实践中的复杂工况时,扩展应用较为困难。美国国家航天局(NASA)的Ames研究中心对电磁干扰下的EMA进行了故障模式与影响分析,提出了基于EMA动力学模型和观测器的混合诊断方法^[7]。该方法同样需要准确的EMA模型,并且需要人工设计特征集和诊断树。基于模型的方法常用于EMA的故障诊断方面,而寿命预测方面研究较少。文献[8]建立简化模型预测EMA的电流。文献[9]利用辅助特征改进卡尔曼滤波器估计EMA的电机电压。由此可知,基于模型的方法通常难以直接预测EMA的剩余寿命(RUL),往往是预测电流电压等性能参数。

数据驱动的方法使用监测数据和信号处理技术,利用EMA的正常和故障数据建立数据模型,从而学习EMA的故障规律。数据驱动的方法可以直接使用

传感器数据,随着监测技术和计算能力的提高,数据驱动方法比基于模型的方法更受欢迎。文献[10]使用功率谱密度方法提取EMA的振动信号的频域特征,之后使用主成分分析降低频域特征维度,最后通过贝叶斯分类器实现故障诊断。文献[11]基于集合经验模式分解方法提取各频段包含的故障特征,实现EMA的故障诊断。文献[12]利用变分模态分解、多重分形去趋势波动分析和概率神经网络对EMA进行故障诊断。文献[13]提出一种基于交互式多模型和无迹卡尔曼滤波相结合的EMA突变故障诊断方法。文献[14]针对EMA渐变故障提出基于动态小波神经网络的方法开展故障诊断。这些传统数据驱动方法通常是人工设计特征提取方法,之后通过神经网络等分类器实现故障诊断。这类方法对预定义的领域知识依赖性较强,工作效率较低,工程扩展能力较弱。近年来,深度学习在EMA的故障预测与健康领域有一定研究。深度学习方法不需要依靠高水平的专家知识,可以自动识别数据的深层结构和高层抽象特征,从而自动提取数据内部的固有特征。文献[15]提出一种基于一维卷积神经网络的EMA故障诊断方法,能够自动提取信号特征。文献^[16]使用深度自动编码器(DAE)将EMA的多模态传感器数据组成的高维数据转换到低维潜在空间,再从低维空间重构特征数据,最后使用重构误差作为异常分数实现了异常检测。文献[17]提出了一种滑窗增强的基于改进的长短时记忆(LSTM)神经网络的EMA故障检测与故障隔离方法。文献^[18]提出了一种基于卷积神经网络(CNN)和最大平均偏差的EMA故障诊断方法。

虽然数据驱动的方法在EMA的故障诊断方面取得了良好成果,但是关于EMA的寿命预测研究较少。NASA提出基于高斯过程回归(GPR)的剩余寿命预测方法^[19]。文献[20]利用加权Bagging方法改进基于GPR的寿命预测方法。但是GPR类方法在每次预测时均需对历史数据随机抽样,计算量很大,预测稳定度较差。

综上所述,虽然EMA在航空航天装备中占据重要位置,尤其是EMA的滚珠丝杠故障是航空航天装备的关键单点故障之一,但是对EMA故障领域的研究主要集中在故障诊断方面,对其寿命预测的研究较少。EMA的寿命预测问题的难点在于EMA结构复杂,具有多种类型的机电类型参数,各参数间相互影响,难以通过对个别参数的行为规律建模实现对其寿命退化规律的认知。以往基于GPR等算法的寿命预测方法只能处理个别参数,导致寿命预测准确率不高、寿命预测起始点距离寿命终止点过近等问

题。

因此,目前在EMA的故障预测与健康管理领域的研究存在以下不足:

1) 基于模型的方法计算成本较高,而且难以获得在复杂环境下的高保真的模型;

2) 传统数据驱动方法常需要大量的专家知识,自动化和自适应能力较弱;

3) 现有基于深度神经

网络的方法在工程扩展性和解决长期数据依赖性方面能力较弱;

4) EMA的故障诊断方面有一定研究,但是对其寿命预测的研究较少。

因此,面向日益复杂的航天器设计,亟需使用新一代智能数据驱动方法,开展能够识别长时间序列数据内部特性的EMA寿命预测技术研究。

近年来,注意力机制在基于深度学习的数据驱动方法中受到广泛关注。注意力机制可以自主学习原始数据的权重分配策略,进一步提高时间序列的特征表示能力。文献[21]提出在门控循环单元上使用注意力机制的方法估计EMA的电机电压,进而实现故障诊断。注意力机制可以学习原始数据的权重分配策略,提高对时间序列的特征表示能力。但是门控单元仍然属于循环神经网络(RNN)的范畴,该方法对长时间序列的表征能力有限。Transformer^[22]是首个完全基于自注意力机制的深度神经网络,常用于序列到序列的建模,可以捕捉输入时间序列内的依赖关系,不受序列内距离的影响。同时Transformer能够并行计算,相比于只能串行计算的RNN极大地提升了运行速度。Transformer已在自然语言处理、计算机视觉、声音处理等多个领域取得优异效果。

鉴于Transformer在多个领域取得的突出有益效果和巨大成功,而EMA的寿命预测领域未见相关研究成果^[23]。本文将引入EMA的寿命预测领域,通过重新设计的Transformer模型,使其在具备模型的长时间序列建模能力的同时,适用于EMA寿命预测任务。本文基于Transformer的设计原理,考虑到EMA的复杂结构和多样化功能,设计多模态Transformer模型,从而使得Transformer模型可将EMA的多模态数据作为输入,将剩余寿命作为输出,

最终实现EMA的寿命预测。

考虑到航空航天装备的高可靠使用要求、多阶段任务需求和多层级运维现状,对EMA的自主健康管理设计不仅要求在其寿命退化初期实现寿命预测,更要求预测其关键性能参数的退化趋势。然而以上两项寿命预测需求是矛盾的,通常难以在寿命退化初期准确预测关键性能参数的长期退化趋势。

为解决上述现实需求相互矛盾而无法同时满足的问题,本文设计多模态Transformer模型,通过Transformer模型的编码器和解码器结构分别实现EMA的直接寿命预测和间接寿命预测。直接寿命预测方式是指多模态Transformer模型的第一种输出,即直接输出预测的剩余寿命,可实现在EMA性能退化早期实时直接地预测其剩余寿命。间接寿命预测方式是指多模态Transformer模型的第二种输出,即在性能退化到一定程度时,输出关键特征参数的时序预测值,通过计算关键特征参数到达寿命阈值的时间,从而间接预测剩余寿命。

本文提出了一种解决航空航天装备中EMA寿命预测问题的新思路,特别是满足了相互矛盾的现实需求,攻克了多阶段多层次寿命预测难题。具体创新点包括:

1) 针对EMA的复杂行为特点,提出利用EMA的多模态传感器数据进行寿命预测的方法;

2) 设计针对EMA的多模态时间序列数据的Transformer模型,解决寿命预测中的时间序列数据的长时间依赖问题;

3) 设计直接和间接两种方式的寿命预测方法,实现了性能退化早期和性能退化中期不同需求特点的寿命预测。

1 Transformer 模型

注意力机制源于对人类观察行为的分析。人类在观察事物时会选择性地注意力投放在其中的一部分事物中,而选择性地忽略其他部分,这种机制被称为注意力机制。自注意力机制重点在序列内部运用注意力机制寻找序列内部的关联关系。Transformer完全基于自注意力机制设计,可以识别时间序列内相关的特别的行为特征,能够更好地对时间序列建模。原始的Transformer模型如图1所示。

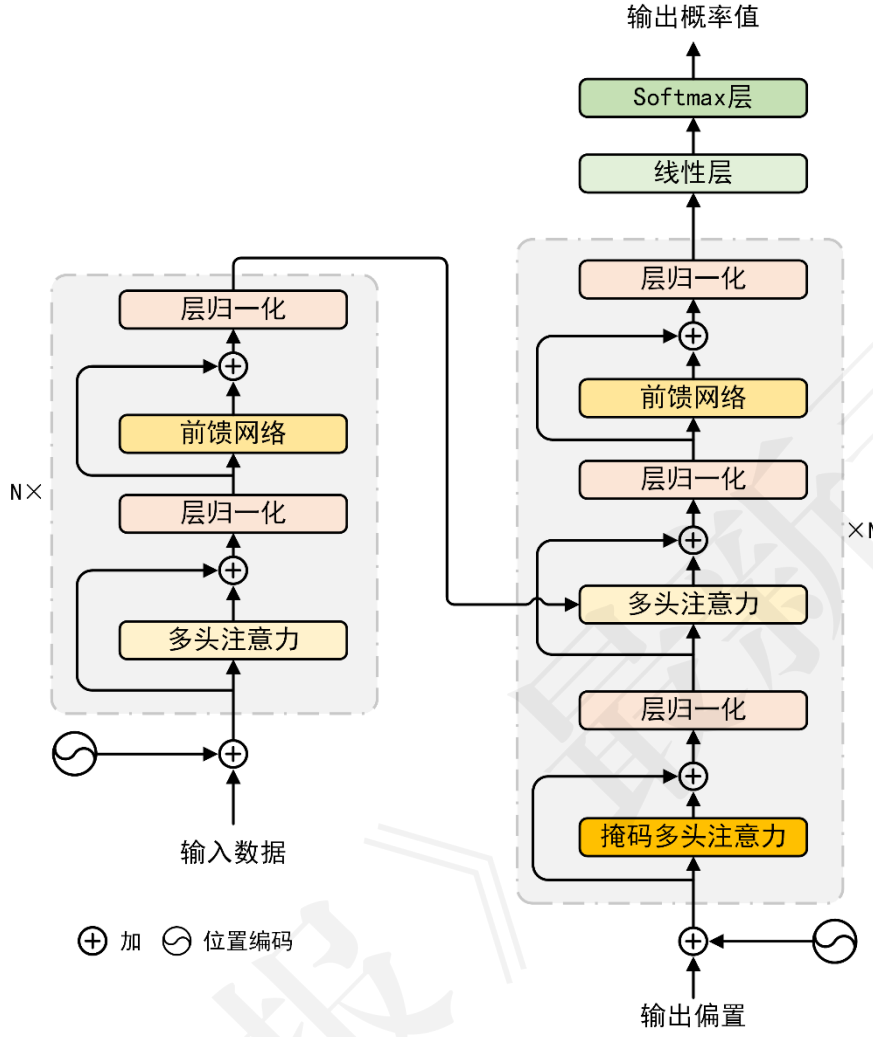


图1 原始 Transformer 模型架构
Fig.1 Architecture of the Transformer

1.1 位置编码

基于时间序列的输入向量的各个数值之间具有固定的时序关系，完全基于自注意力机制的编码器和解码器不能考虑位置信息。Transformer通过位置编码将序列的时间信息加入输入向量，为整合后的输入提供有意义的时间序列内的距离关系。本文提出的多模态Transformer模型使用正弦和余弦函数实现位置编码。

$$\begin{cases} PE_{(pos, 2i)} = \sin(pos / 10000^{2i/d_{model}}) \\ PE_{(pos, 2i+1)} = \cos(pos / 10000^{2i/d_{model}}) \end{cases} \quad (1)$$

式中： pos 表示向量中元素位置； i 表示维度； d_{model} 表示模型维度。位置编码的每个维度对应一个正弦信号。

1.2 编码器

定义经位置编码后的输入时间序列矩阵为 X 。编码器将其映射到编码空间，构成编码向量。编码器层由 N 个相同的编码器堆叠构成。每一编码器都

由两个模块组成：第1个是多头注意力模块，第2个是全连接前馈神经网络模块。在两个模块中，每一模块都采用残差连接，并进行层归一化处理。

多头注意力是指同时使用多个注意力机制，自注意力机制首先处理输入序列矩阵，计算 Q 、 K 、 V 矩阵。

$$\begin{aligned} Q &= XW_Q \\ K &= XW_K \\ V &= XW_V \end{aligned} \quad (2)$$

式中： W_Q 、 W_K 、 W_V 是权重矩阵，各权重矩阵维度表示为 $Q \in \mathbb{R}^{n \times d_k}$ 、 $K \in \mathbb{R}^{m \times d_k}$ 、 $V \in \mathbb{R}^{m \times d_v}$ 。

之后计算注意力：

$$A = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3)$$

注意力的计算过程相当于求 Q 和 K 的相似度，即计算余弦相似度后经softmax函数归一化。这些相似度值相当于计算输入序列的加权平均，可以识别输

入序列中哪些部分是重要的。 $\sqrt{d_k}$ 起到调节作用,使得内积不至于太大,防止softmax计算后的结果非0即1。最后通过与 V 相乘得到最终的注意力。因此,注意力机制实际上是对输入数据的识别,通过权重分布的机制获取重要信息,选择性忽略不重要信息。

多头注意力是指使用多个自注意力机制分别计算注意力,再将其融合的过程。多头注意力机制扩展了模型专注于不同位置的能力,提供了多个自注意力表示子空间,从而在不同时刻、不同情况下关注输入序列的不同位置。

多头注意力模型将 Q 、 K 、 V 通过投影矩阵进行线性映射,然后再分别计算 h 次注意力,最后将结果进行拼接。单个注意力的计算过程为

$$head_i = A(QW_{i,Q}, KW_{i,K}, VW_{i,V}) \quad (4)$$

式中: $W_{i,Q}$ 、 $W_{i,K}$ 、 $W_{i,V}$ 是第 i 个自注意力机制的映射矩阵,其中各映射矩阵的维度大小分别表示为 $W_{i,Q} \in \mathbb{R}^{d_{model} \times d_k}$ 、 $W_{i,K} \in \mathbb{R}^{d_{model} \times d_k}$ 、 $W_{i,V} \in \mathbb{R}^{d_{model} \times d_v}$ 。

投影矩阵的作用是将 Q 、 K 、 V 投影到 h 个不同的侧重点,从而学习到不同的注意力,提高模型的准确性。最后将所有注意力结果拼接。

$$M(Q, K, V) = \text{Concat}(head_1, \dots, head_h)W_o \quad (5)$$

式中: M 表示多头注意力; $W_o \in \mathbb{R}^{hd_v \times d_{model}}$ 是拼接之后的线性映射矩阵。

多头注意力机制进行了 h 次参数不共享的自注意力计算,使得模型可以在不同的表示子空间里学习到不同的信息。残差结构的作用是为模型深度过深时,梯度不会为0。层归一化能够将经过的向量值映射到0-1之间,加快模型的收敛速度。

层归一化是对输入 x 归一化,具体计算表示为

$$\text{LayerNorm}(x) = \gamma \frac{(x - \mu_x)}{\sigma_x} + \beta \quad (6)$$

式中: $\text{LayerNorm}(x)$ 是层归一化的输出; γ 和 β 是调节参数; μ_x 和 σ_x 是 x 的均值和标准差。

1.3 解码器

N 个解码器堆叠构成的解码器层。每个解码器均接受最后一个编码器的输出,同时解码器层将自身的上一时刻输出作为下一时刻的输入。

解码器除了与编码器相同的两个模块之外,解码器还添加了掩码多头注意力模块。该模块用于对编码器组的输出执行掩码多头注意力计算。与编码器类似,解码器的每个子层也采用残差连接,并进行层归一化处理。

解码器和编码器不同,解码器计算输出的时候,无法获取此后时间的输入时间序列,因此需要屏蔽后续时间的输入,该方法称为掩码。

$$MA(Q, K, V) = \text{softmax}\left(\frac{QK^T + Mk}{\sqrt{d_k}}\right)V \quad (7)$$

式中: MA 表示掩码多头注意力; Mk 表示掩码。

解码器中的自注意力与编码器中的自注意力的运行方式不同:在解码器中的自注意力只允许关注输出序列中较早的位置。这是在计算softmax步骤之前通过掩码屏蔽未来位置完成。

每一编码器和解码器都包含一个全连接前馈神经网络模块。前馈模块是由两个全连接神经网络串行连接而成。每个全连接网络有独立的权重、偏差和维度,能够进一步提取信息。第1个全连接神经网络使用ReLU激活函数,第2个不使用激活函数。计算公式为

$$FFN(x) = \text{ReLU}(xW_1 + b_1)W_2 + b_2 \quad (8)$$

式中: W_1 、 b_1 、 W_2 、 b_2 分别为前馈神经网络的权重和偏差。

2 多模态 Transformer 模型

本文面向EMA的多传感器数据组成的综合的时间序列,建立多模态Transformer模型,实现直接和间接两种方式预测EMA剩余寿命。本文提出的多模态Transformer模型的总体架构如图2所示。

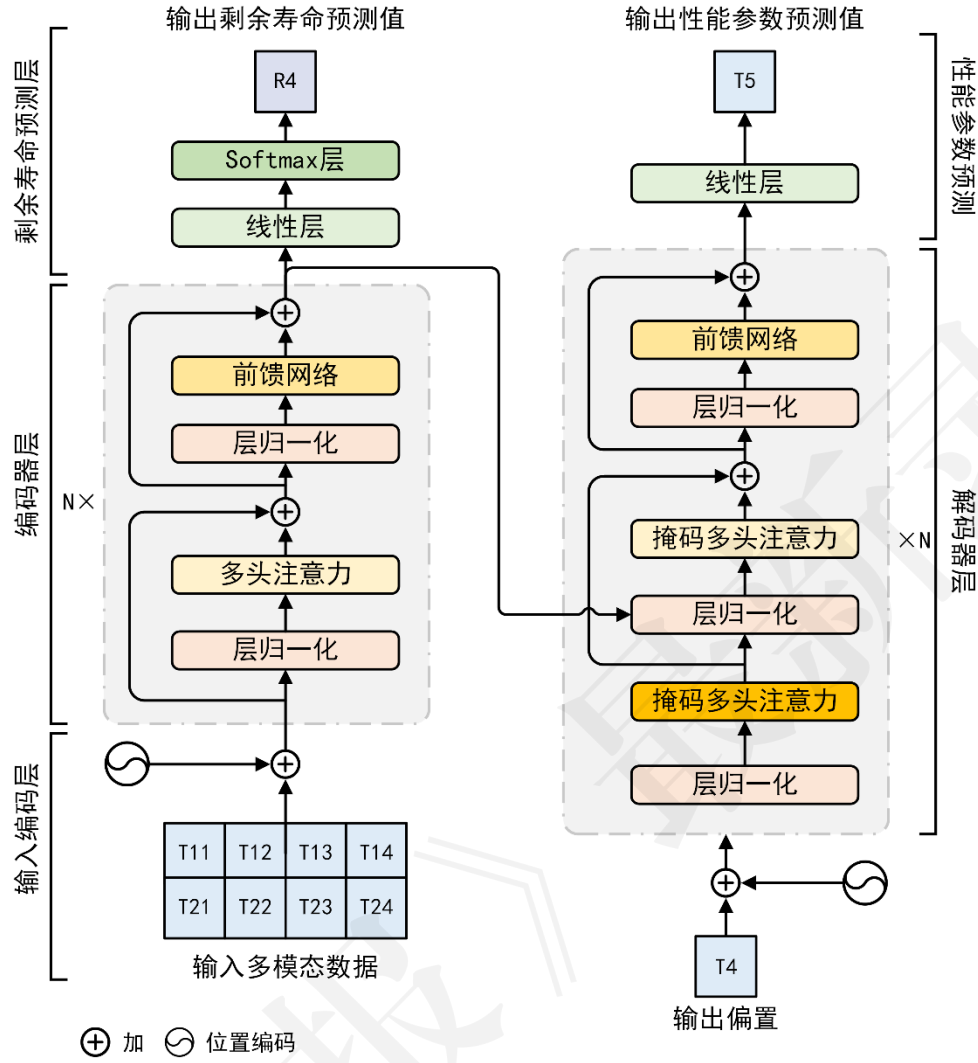


图 2 多模态 Transformer 模型架构

Fig.2 Architecture of the multimode Transformer

针对EMA的寿命预测问题,本文在使用多模态数据的基础上,为了优化梯度路径、增强梯度稳定性、增强时间序列全局信息分别做了改进。此外,为了适用于EMA的实际使用场景,本文对多模态Transformer模型的输出部分进行改进,使其既能输出直接的剩余寿命,又能间接地预测关键参数的寿命退化过程。

2.1 梯度路径优化

残差连接在缓解深度神经网络结构信息衰减方面起着至关重要的作用。然而原始的Transformer模型在残差连接后增加了一系列层归一化操作。在初始化时,输出层附近参数的期望梯度很大^[24]。为了优化梯度路径,本文提出的多模态Transformer模型将层归一化移动到解码器和编码器子模块的输入以及残差连接之前。这样就形成了从输出到输入的直通式梯度路径,而不需要任何转换。

基于该改进,多头注意力的输出表示为

$$Y_M = X + MA(\text{LayerNorm}(X)) \quad (9)$$

式中: Y_M 表示多头注意力的输出; X 表示其输入。

基于该改进,前馈神经网络的输出表示为

$$Y_F = Y_M + FFN(\text{LayerNorm}(Y_M)) \quad (10)$$

式中: Y_F 表示前馈神经网络的输出。

2.2 增强梯度稳定性

残差连接在缓解深度神经网络结构信息衰减方面起着至关重要的作用。然而原始的Transformer模型在残差连接后增加了一系列层归一化操作。受文献[24]的启发,将层归一化移动到解码器和编码器子模块的输入以及残差连接之前。这样就形成了从输出到输入的直通式梯度路径,而不需要任何转换。

为了提高编码器层的收敛性,本文采用了高斯误差线性单元(GeLU)激活函数^[25]代替ReLU激活函数。对于任何输入 v ,GeLU被定义为输入 v 和掩码 u 的乘积。

$$u \sim \text{Bernoulli}(\Phi(v))$$

$$\Phi(v) = P(V \leq v) \quad (11)$$

$$V \sim \mathcal{N}(0,1)$$

式中： $\Phi(\cdot)$ 是标准高斯分布函数， $\mathcal{N}(\cdot)$ 是标准正态分布的累积分布函数。

在此基础上，GeLU函数可被定义为

$$\text{GeLU}(v) = vP(V \leq v) = v\Phi(v) = 0.5v(1 + \text{erf}(v/\sqrt{2})) \quad (12)$$

式中： $\text{erf}(\cdot)$ 表示高斯误差函数，

$$\text{erf}(v) = 2/\sqrt{\pi} \int_0^v e^{-t^2} dt \quad (13)$$

因此，GeLU函数可由近似计算得出：

$$\text{GeLU}(v) = v\sigma(1.702v) = \frac{v}{2}(1 + \tanh(\sqrt{\frac{2}{\pi}}(v + 0.044715v^3))) \quad (14)$$

GeLU激活是连续可微的，在 $v = 0$ 处比ReLU激

活具有更明显的非线性。

基于以上改进，前馈神经网络的输出为

$$FFN(x) = \text{GeLU}(xW_1 + b_1)W_2 + b_2 \quad (15)$$

2.3 时间序列全局信息增强

为了准确预测EMA的剩余寿命，模型应能够在充分利用局部信息的基础上，尽可能保留全局的原始多模态时间序列信息。因此，本文使用颗粒度一致注意力^[26]的方式增强时间序列的全局信息保留能力，同时加强解码和编码过程，充分利用模型的表达能力。

基于颗粒度一致注意力的多模态Transformer模型的解码器和编码器序列组合关系如图3所示。

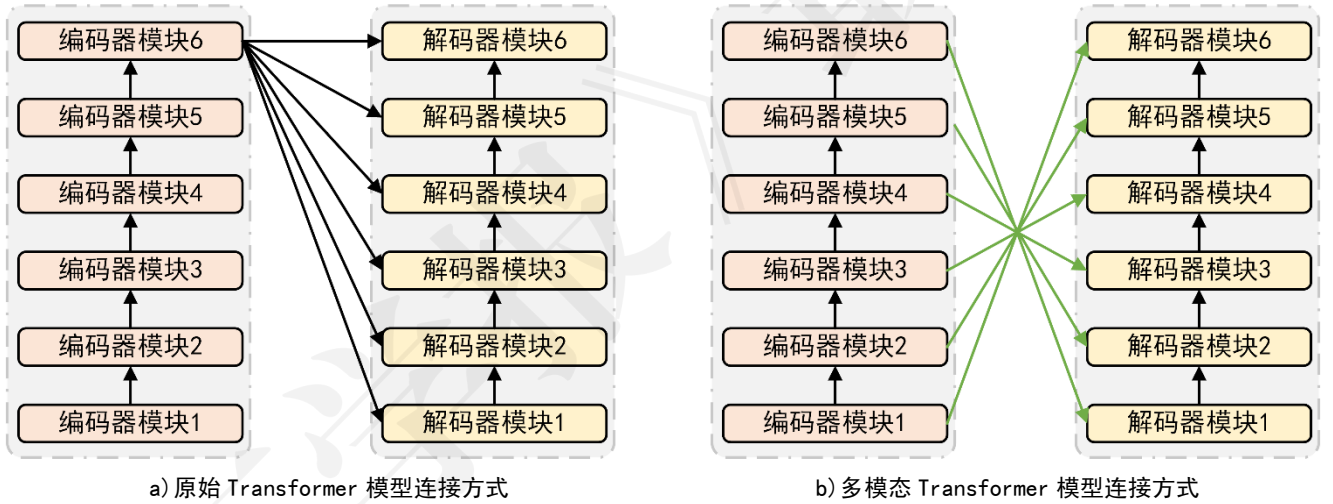


图3 基于颗粒度一致注意力的改进方式

Fig.3 An improved approach based on Granularity Consistent Attention

原始的Transformer模型仅将最后一个编码器模块的输出连接到解码器模块，本文提出的多模态Transformer模型使用颗粒度一致注意力的方式，更符合多层编码和解码过程的特点。

2.4 模型输出符合实际用途

原始的Transformer模型用于序列到序列的建模，其输出仅能预测时间序列的后续发展。本文提出的多模态Transformer模型的输出部分包括直接剩余寿命输出和关键参数预测输出。

剩余寿命输出部分将编码器层的输出经全连接神经网络和softmax处理后得到各个时刻直接预测的剩余寿命。


关键参数预测部分将解码器层的输出经全连接

神经网络和softmax处理后得到各个时刻预测的后续关键参数。通过关键参数预测曲线和参数阈值间接计算剩余寿命。


2 试验验证

2.1 EMA 寿命退化试验

为了验证本文提出的寿命预测方法的有效性，本文利用NASA的可飞式机电作动器（FLEA）试验数据进行验证。FLEA试验台如图4所示，FLEA试验台包含3个不同的作动器：故障注入作动器X、正常作动器Y、动态负载作动器Z。测试中将负载从正常作动器切换到故障作动器，可以在不改变作动器工作的情况下实现故障注入。



(a) 试验装置



(b) 试验原理

图 4 FLEA 试验台

Fig.4 FLEA Test Bed

EMA由电气部分和机械部分组成，故障类型包括：传感器故障、电机故障、机械故障和电子故障。其中传感器故障和电子故障与其他航空航天系统的同类故障没有显著差异。电机故障表示为电流变化，故障特征显著，早期故障诊断较为容易。机械故障是航天应用中的关注焦点，其中轴承和齿轮箱部分的故障诊断已有很多研究^[27-28]。机械结构中减速器等可以通过余度设计提高可靠性，但是滚珠丝杠难以实现余度设计。滚珠丝杠作为EMA的关键功能部件，其故障成为机电作动器的单点故障，其中阻塞故障是滚珠丝杠的关键渐变故障之一。一般情况下，堵塞发生后EMA仍需要工作一段时间。因此早期阻塞故障发生后，预测EMA的剩余寿命对航天器非常重要，对保障航天器安全具有重要意义。因此，本文主要针对EMA堵塞故障发展过程的寿命预测开展研究。

FLEA试验中，阻塞故障是通过安装在滚珠丝杠返回通道上的机构减缓轴承球的循环而注入的。FLEA试验以100Hz的采样率获取作动器位置、电压、电流、温度等数据。共计13种数据可被用于分析：时间、作动器Z位置、动态负载、电机X电流、电机Y电流、电机Z电流、电机X电压、电机Y电压、电机Y温度、电机Z温度、螺母X温度、螺母Y温度、环境温度。

一般情况下，只有部分参数可以为剩余寿命预测提供有用信息^[29]。与故障作动器X直接相关的数据包括：作动器X位置，电机X电流，电机X电压，电机X温度和螺母X温度。堵塞发生时，滚珠丝杠螺母中摩擦增加，导致控制器将额外的电流输入到作动器X电机，从而尝试在相同的负载下与作动器Y执行相同的运动曲线。这种过高的电流导致电机外壳内的热量逐渐积聚。过热最终导致绕组绝缘损坏、

短路和电机故障等。在相同的负载下，作动器X和作动器Y的电机温度如图5所示。




图 5 -40lbs 载荷时作动器 X 和作动器 Y 的电机温度

Fig.5 Temperature of motor housing with -40 lbs load

由图5可以看出，存在阻塞故障的作动器X的电机温度与正常作动器Y的电机温度显著不同。X电机温度表现出持续上升的趋势，验证了电机X温度能表征EMA阻塞故障的变化规律的故障机理。电机使用寿命的降低与电机温度的持续升高有关，电机温度可作为寿命预测的关键特征参数。

一旦电机温度超过上限，即可认为EMA寿命终止。一般而言，可将电机温度阈值设置为88℃^[19]，稳定达到寿命阈值的时刻作为寿命终止（EoL）时刻。在通常的寿命预测试验中，为了验证寿命预测的效果，可将不同条件下的作动器寿命阈值设置为70℃或55℃^[20]。

2.2 寿命预测性能指标

在寿命预测相关的研究领域，常使用平均百分比误差（MAPE）和S分数作为寿命预测的评价指标。MAPE评价寿命预测的平均精度，对任何预测结果均采取相同的权重，因此本文使用MAPE评估间接

寿命预测的性能，也就是评估关键性能参数的预测精度。剩余寿命高估(剩余寿命预测值大于真实值)时，会造成后续预防策略的误判，甚至造成安全问题。因此在模型的评价过程中需要对高估的剩余寿命预测值施加更多的惩罚，在评价标准中产生更多的负面影响。 S 分数的非对称函数的特点满足上述要求。本文使用 S 分数评估直接寿命预测的精度。 $MAPE$ 和 S 分数的计算公式如下。

$$MAPE = \sum_{i=1}^N \left| \frac{\hat{y}_i - y_i}{y_i} \right| \times \frac{100}{N} \quad (16)$$

$$S = \begin{cases} \sum_{i=1}^N \left[\exp\left(-\frac{\hat{y}_i - y_i}{13}\right) - 1 \right] & , \hat{y}_i \leq y_i \\ \sum_{i=1}^N \left[\exp\left(\frac{\hat{y}_i - y_i}{10}\right) - 1 \right] & , \hat{y}_i > y_i \end{cases} \quad (17)$$

式中： \hat{y}_i 表示预测值； y_i 表示真实值； N 表示测试样本数。

2.3 寿命预测验证试验

本文使用动态负载、电机 X 电流、电机 X 电压、螺母 X 温度和电机 X 温度作为多模态时间序列作为输入，预测剩余寿命。所用数据的试验工况如表1所示。

表 1 试验工况

Table 1 Experiment conditions

负载类型	幅值/mm	频率/Hz	负载/lbs	最大速度/(m·s ⁻¹)
正弦	80	0.25	-40	0.04

试验中部分EMA最终温度达到100℃左右完全停止试验，在88℃时已无法完成正常功能，被认为寿命完全终止。部分EMA在70℃时已完全失效，无法继续进行试验。为了显示这两类EMA试验数据的区别，分别对这两类EMA各取一个试验样本，绘制其寿命试验数据，如图6所示。

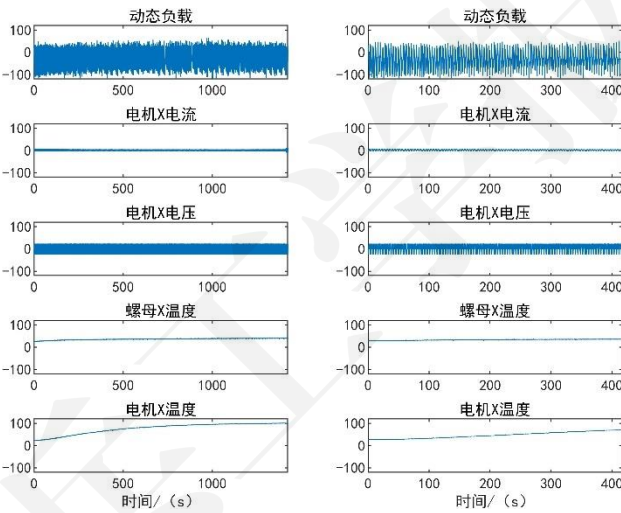


图 6 EMA 寿命试验数据

Fig. 6 Overview of EMA degradation test data

图6分为左右两部分，左侧是最终电机温度达到100℃左右的EMA的寿命试验数据，右侧是最终电机温度达到70℃左右的EMA的寿命试验数据。首先，以最终电机温度达到100℃左右的EMA的寿命试验数据作为训练数据，以最终电机温度达到70℃左右的EMA的寿命试验数据作为测试数据，验证基于多模态Transformer的编码器的直接剩余寿命预测方法。之后，本文以部分最终电机温度达到100℃左右的

EMA的寿命试验数据作为训练数据，以其他最终电机温度达到100℃左右的EMA的寿命试验数据作为测试数据，预测这些EMA的电机温度，验证基于多模态Transformer模型的间接寿命预测方法。

试验中电机温度达到70℃左右的EMA在399 s时完全失效，直接寿命预测结果如下图所示。为了简化测试，本试验中每秒取一次数据进行预测，图中真实剩余寿命和预测剩余寿命均有398个数值，预测结果的 S 分数是656.69。

目前关于EMA的寿命预测研究较少，没有发现类似的针对EMA开展的直接寿命预测研究。为对比本文所提出的方法的有效性，本文使用常规的LSTM神经网络和一维CNN神经网络进行性能对比，分别使用上述方法进行直接寿命预测，对比结果如表2所示。

表 2 直接寿命预测性能对比

Table 2 Performance comparison of direct RUL methods

序号	模型名称	S 分数
1	1DCNN	1503.86.
2	LSTM	1387.51
3	多模态 Transformer	656.69

由此可知本文所提出的基于多模态Transformer的编码器的直接寿命预测方法能够以较高的精度实时直接预测EMA的剩余寿命，如图7所示。




图 7 剩余寿命预测

Fig.7 Prediction of RUL

电机温度可以直观地显示EMA的性能退化过程, 寿命退化试验持续进行至电机温度达到100℃, 此时EMA完全失效。试验中EMA在735 s时电机温度达到88℃, 从而丧失正常功能, 可认为其寿命终止。本文所述的间接寿命预测结果如图8所示。




图 8 电机 X 温度预测

Fig.8 Prognostic of motor X temperature

为了简化测试, 本试验中每秒取一次数据进行预测, 上图中真实电机温度和预测电机温度均有986个数值, 预测误差MAPE是1.45。通过预测电机X温度, 并与温度阈值88℃比较, 可知预测寿命终止的时间是722 s, 真实寿命终止是735 s, 预测值与真实值较为接近。

为对比本文所提出的方法的有效性, 本文使用NASA提出的传统的曲线拟合(统计分布估计)类方法GPR、LSTM深度神经网络、原始Transformer模型进行性能对比, 分别使用上述方法进行间接寿命预测, 对比结果如表3所示。

表 3 间接寿命预测性能对比

序号	模型名称	MAPE
1	GPR	6.62
2	LSTM	5.01
3	原始 Transformer	2.33
4	多模态 Transformer	1.45

由此可知本文所提出的基于多模态Transformer

的关键性能参数预测效果较好, 间接寿命预测方法能够以较高的精度预测EMA的关键性能参数的发展趋势, 并间接计算其剩余寿命。

3 结论

面向航空航天装备领域应用日益广泛的机电作动器, 面向当前寿命预测研究较少的现状, 针对航空航天领域对EMA寿命预测的互斥的应用需求, 本文提出了一种基于多模态Transformer的机电作动器直接寿命预测及关键性能参数预测方法。本文提出的多模态Transformer的编码器部分通过多头注意力机制自适应提取多传感器时间序列的寿命特征, 从而直接预测机电作动器的剩余寿命。多模态Transformer的编码器和解码器部分组合起来预测多传感器时间序列中关键性能参数的退化趋势, 通过自回归的方式持续输出预测值, 最终与关键性能参数的故障阈值比较, 从而间接预测机电作动器的剩余寿命。本文提出的多模态Transformer是端到端(End-to-End)的架构, 无需任何人工设计特征及相关预处理过程, 模型直接获取原始多传感器时间序列数据, 实时输出各时间点的机电作动器剩余寿命及关键性能参数预测序列。最后通过机电作动器寿命试验数据验证了本文所提方法的有效性。试验结果表明本文所提出的方法用于直接寿命预测时, 预测性能指标S分数是656.69, 明显优于常规的LSTM和CNN方法; 该方法用于间接寿命预测时, 性能指标参数MAPE是1.45, 明显优于NASA提出的基于GPR的常规方法、基于深度神经网络的LSTM和CNN方法。以上结果表明本文所提出的方法在直接剩余寿命预测和间接剩余寿命预测时均有很高的精度。

本文提出的直接剩余寿命预测部分可以在EMA使用过程中, 尤其是故障早期直观地预测剩余寿命, 可为早期应急管理奠定基础。当EMA性能退化中期, 间接寿命预测方法可以直观地显示关键特征参数的发展规律, 并预测剩余寿命。可让地面运维人员直观地看到EMA寿命退化曲线, 方便结合专家知识实现精准的中后期应急处置。

未来将使用更多的数据驱动方法在多种不同工况的机电作动器寿命试验数据上测试, 并横向比较各方法性能。同时, 将EMA的其他故障模式纳入测试, 验证本文提出方法的有效性。

参考文献 (References)

- [1] MAZZOLENI M, DI RITO G, PREVIDI F. Electro-mechanical actuators for the more electric aircraft[M]. Cham, Switzerland: Springer Cham, 2021.

- [2] 郭忠义, 李永华, 李关辉, 等. 装备系统剩余使用寿命预测技术研究进展[J]. 南京航空航天大学学报, 2022, 54(03): 341-364.
GUO Z Y, LI Y H, LI G H, et al. Research progress on remaining useful life prediction technology of equipment systems[J]. Journal of Nanjing University of Aeronautics & Astronautics, 2022, 54(3):341-364. (in Chinese)
- [3] DALLA VEDOVA M D L, GERMANÀ A, BERRI P C, et al. Model-based fault detection and identification for prognostics of electromechanical actuators using genetic algorithms[J]. Aerospace, 2019, 6(9): 94.
- [4] ARRIOLA D, THIELECKE F. Model-based design and experimental verification of a monitoring concept for an active-active electromechanical aileron actuation system[J]. Mechanical Systems and Signal Processing, 2017, 94: 322-345.
- [5] OSSMANN D, VAN DER LINDEN F L J. Advanced sensor fault detection and isolation for electro-mechanical flight actuators[C]//Proceedings of 2015 NASA/ESA Conference on Adaptive Hardware and Systems. Montreal, QC, Canada:IEEE,2015.
- [6] DI RITO G, LUCIANO B, BORGARELLI N, et al. Model-based condition-monitoring and jamming-tolerant control of an electro-mechanical flight actuator with differential ball screws[J]. Actuators, 2021, 10(9): 230.
- [7] BALABAN E, SAXENA A, NARASIMHAN S, et al. Prognostic health-management system development for electromechanical actuators[J]. Journal of Aerospace Information Systems, 2015, 12(3): 329-344.
- [8] BERRI P C, DALLA VEDOVA M D L, MAGGIORE P. A simplified monitor model for EMA prognostics[J]. MATEC Web of Conferences, 2018, 233:00016.
- [9] ZHANG Y J, LIU L S, PENG Y, et al. An electro-mechanical actuator motor voltage estimation method with a feature-aided Kalman filter[J]. Sensors, 2018, 18(12): 4190.
- [10] CHIRICO A J III, KOLODZIEJ J R. A data-driven methodology for fault detection in electromechanical actuators[J]. Journal of Dynamic Systems, Measurement, and Control, 2014, 136(4): 041025.
- [11] 刘俊, 王占林, 付永领, 等. 基于 EEMD 分解的直驱式机电作动器故障诊断[J]. 北京航空航天大学学报, 2012, 38(12): 1567-1571.
LIU J, WANG Z L, FU Y L, et al. Fault diagnosis of direct-driven electromechanical actuator based on ensemble empirical mode decomposition[J]. Journal of Beijing University of Aeronautics and Astronautics, 2012, 38(12): 1567-1571. (in Chinese)
- [12] LIU H M, JING J Y, MA J. Fault diagnosis of electromechanical actuator based on VMD multifractal detrended fluctuation analysis and PNN[J]. Complexity, 2018, 2018: 9154682.
- [13] 王剑, 王新民, 谢蓉, 等. 基于 IMM-UKF 方法的机电作动器突发性故障诊断研究[J]. 北京理工大学学报, 2019, 39(2): 198-202, 208.
WANG J, WANG X M, XIE R, et al. Abrupt fault diagnosis for electro-mechanical actuator based on IMM-UKF[J]. Transactions of Beijing Institute of Technology, 2019, 39(2): 198-202, 208. (in Chinese)
- [14] 王剑, 王新民, 谢蓉, 等. 基于 DWNN 的机电作动器渐变故障诊断[J]. 北京航空航天大学学报, 2019, 45(9): 1831-1837.
WANG J, WANG X M, XIE R, et al. Gradual fault diagnosis for electromechanical actuator based on DWNN[J]. Journal of Beijing University of Aeronautics and Astronautics, 2019, 45(9): 1831-1837. (in Chinese)
- [15] 李世晓, 杜锦华, 龙云. 基于一维卷积神经网络的机电作动器故障诊断[J]. 电工技术学报, 2022, 37(增刊): 62-73.
LI S X, DU J H, LONG Y. Fault diagnosis of electromechanical actuators based on one-dimensional convolutional neural network[J]. Transactions of China Electrotechnical Society, 2022, 37(S1): 62-73. (in Chinese)
- [16] REDDY K K, SARKAR S, VENUGOPALAN V, et al. Anomaly detection and fault disambiguation in large flight data: a multi-modal deep auto-encoder approach[C]//Proceedings of 2016 Annual Conference of the Prognostics and Health Management Society. Denver, CO, US: Prognostics and Health Management Society, 2016:207-214.
- [17] YANG J, GUO Y Q, ZHAO W L. Long short-term memory neural network based fault detection and isolation for electro-mechanical actuators[J]. Neurocomputing, 2019, 360: 85-96.
- [18] SIAHPOUR S, LI X, LEE J. Deep learning-based cross-sensor domain adaptation for fault diagnosis of electro-mechanical actuators[J]. International Journal of Dynamics and Control, 2020, 8(4): 1054-1062.
- [19] BALABAN E, SAXENA A, NARASIMHAN S, et al. Experimental validation of a prognostic health management system for electro-mechanical actuators[C]//Proceedings of AIAA Infotech@Aerospace. St. Louis, MI, US: American Institute of Aeronautics and Astronautics, 2011:AIAA2011-

- [20]ZHANG Y J, LIU D T, YU J X, et al. EMA remaining useful life prediction with weighted bagging GPR algorithm[J]. *Microelectronics Reliability*, 2017, 75: 253-263.
- [21]ZHANG X Y, TANG L W, CHEN J S. Fault diagnosis for electro-mechanical actuators based on STL-HSTA-GRU and SM[J]. *IEEE Transactions on Instrumentation and Measurement*, 2021, 70: 3527716.
- [22]VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]// *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Long Beach, CA, US: Neural Information Processing Systems Foundation, Inc.,2017:6000-6010.
- [23]张玉杰, 彭宇, 刘大同. 飞机机电系统部件数据驱动健康状态在线估计方法综述[J]. *仪器仪表学报*, 2022, 43(6): 118-130.
- ZHANG Y J, PENG Y, LIU D T. Review on data-driven health state on-line estimation methods for aircraft electromechanical system components[J]. *Chinese Journal of Scientific Instrument*, 2022, 43(6): 118-130. (in Chinese).
- [24]XIONG R, YANG Y, HE D, et al. On layer normalization in the transformer architecture[C]//*Proceedings of the 37th International Conference on Machine Learning*. Vienna, Austria:PMLR, 2020: 10524-10533.
- [25]HENDRYCKS D, GIMPEL K. Gaussian error linear units (gelus): arXiv:1606.08415[R/OL]. Ithaca, NY, US: Cornell University.(2020-07-08).
<https://doi.org/10.48550/arXiv.1606.08415>.
- [26]LIU F L, REN X C, ZHAO G X, et al. Rethinking and improving natural language generation with layer-wise multi-view decoding: arXiv:2005.08081[R]. Ithaca, NY, US: Cornell University.(2020-08-29).
<https://arxiv.org/abs/2005.08081>.
- [27]邵怡韦, 陈嘉宇, 林翠颖, 等. 小训练样本下齿轮箱故障诊断: 一种基于改进深度森林的方法[J]. *航空学报*, 2022, 43(8): 118-132.
- SHAO Y W, CHEN J Y, LIN C Y, et al. Gearbox fault diagnosis with small training samples: an improved deep forest based method[J]. *Acta Aeronautica et Astronautica Sinica*, 2022, 43(8): 118-132. (in Chinese)
- [28]李国发, 王彦博, 何佳龙, 等. 机电装备健康状态评估研究进展及发展趋势[J]. *吉林大学学报(工学版)*, 2022, 52(02): 267-279.
- LI G F, WANG Y B, HE J L, et al. Research progress and development trend of health assessment of electromechanical equipment[J]. *Journal of Jilin University(Engineering and Technology Edition)*, 2022, 52(2): 267-279. (in Chinese)
- [29]LIU L S, WANG S J, LIU D T, et al. Entropy-based sensor selection for condition monitoring and prognostics of aircraft engine[J]. *Microelectronics Reliability*, 2015, 55(9/10): 2092-2096.